Práctica 1: Segmentación de Clientes mediante RFM y K-Means

Dataset: Online Retail (UCI Machine Learning Repository — DOI: 10.24432/C5BW33 | CC BY 4.0)

---

1. Contexto y Carga del Dataset

En esta práctica se trabaja con el dataset público **Online Retail** del *UCI Machine Learning Repository*. Contiene **541.909 líneas de transacción** registradas entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011 por una empresa británica de comercio electrónico dedicada a la venta de artículos de regalo y decoración.

Objetivo: Transformar las transacciones en un dataset a nivel de cliente mediante variables **RFM** (*Recency, Frequency, Monetary*) y aplicar **K-Means** para identificar segmentos comercialmente interpretables.

1.1. Descripción detallada de las columnas del dataset

A partir de la salida de `df.info()` (541.909 filas y 8 columnas), se detalla el significado, tipo de dato, recuento de valores válidos y relevancia de cada variable:

Columna	Tipo	No Nulos	Descripción y relevancia para el análisis RFM
InvoiceNo	object (str)	541.909	**Número de factura** (6 dígitos). Si empieza por **'C'** (ej. C536379), indica una cancelación/devolución. Clave para filtrar anulaciones y calcular la *Frequency* (facturas únicas por cliente).
StockCode	object (str)	541.909	**Código de producto** (5 dígitos). Identifica cada artículo distinto del catálogo (incluye códigos especiales como POST o M).
Description	object (str)	540.455 (1.454 nulos)	**Nombre comercial del artículo.** Presenta 1.454 valores nulos en ajustes de stock, pero no interviene en el cálculo de las métricas RFM.
Quantity	int64	541.909	**Unidades adquiridas** en cada línea. Toma valores negativos en devoluciones o mermas de inventario; deben conservarse solo compras reales (Quantity > 0).
InvoiceDate	datetime64	541.909	**Fecha y hora de la transacción** (01/12/2010 a 09/12/2011). Imprescindible para calcular la *Recency* (días desde la última compra del cliente).
UnitPrice	float64	541.909	**Precio unitario** en libras esterlinas (£). Multiplicado por Quantity permite calcular el importe de línea para obtener *Monetary*. Filtrar UnitPrice <= 0.
CustomerID	float64	406.829 (135.080 nulos)	**Identificador único del cliente** (5 dígitos). El **24,93 %** de las filas carecen de CustomerID. Es obligatorio eliminarlas para agregar por cliente.
Country	object (str)	541.909	**País del cliente** (38 países distintos; el 91,43 % de las líneas corresponden a United Kingdom).

2. Exploración Inicial del Dataset Transaccional

Antes de agregar la información por cliente, analizamos en detalle la estructura y calidad de los datos transaccionales:

2.1. Número de filas, columnas y periodo temporal cubierto

- **Dimensiones:** 541.909 filas y 8 columnas.
- **Primera transacción registrada:** 2010-12-01 08:26:00.
- **Última transacción registrada:** 2011-12-09 12:50:00.
- **Periodo temporal cubierto:** 373 días (~12,3 meses, prácticamente un año completo).

2.2. Tipos de datos y conversión de InvoiceDate

Se asegura la conversión explícita de `InvoiceDate` a formato `datetime64[ns]` mediante `pd.to_datetime(df['InvoiceDate'])` para operar con diferencias de fechas, y se normalizan `InvoiceNo` y `StockCode` como cadenas de texto (`str`) para evaluar de forma segura el prefijo `'C'` de las facturas canceladas.

2.3. Valores nulos, especialmente en CustomerID

Solo existen valores nulos en dos columnas del dataset:

- **CustomerID:** 135.080 filas nulas (**24,93 %** del total) frente a 406.829 filas con cliente identificado (75,07 %). Corresponden a compras realizadas sin iniciar sesión o ventas sin ficha de cliente; deberán descartarse porque no es posible asignarlas a ningún cliente individual en el modelo RFM.
- **Description:** 1.454 filas nulas (**0,27 %** del total), asociadas principalmente a ajustes internos de stock sin cliente ni precio.
- El resto de variables (**InvoiceNo, StockCode, Quantity, InvoiceDate, UnitPrice, Country**) tienen **0 nulos**.

2.4. Facturas canceladas y cantidades o precios no positivos

- **Facturas canceladas (InvoiceNo empieza por 'C'):** 9.288 líneas de transacción (1,71 % del dataset), repartidas en **3.836 facturas canceladas únicas**. Todas ellas presentan cantidades negativas.
- **Cantidades no positivas (Quantity <= 0):** 10.624 líneas (1,96 % del total). De ellas, 9.288 pertenecen a facturas canceladas con prefijo 'C' y las **1.336 restantes** son ajustes manuales o bajas de inventario sin prefijo 'C' (y sin CustomerID).
- **Precios unitarios no positivos (UnitPrice <= 0):** 2.517 líneas (0,46 % del total), desglosadas en **2.515 líneas con UnitPrice == 0** (artículos promocionales/regalos o ajustes de almacén) y **2 líneas con UnitPrice < 0** (-11.062,06 £ cada una, bajo el concepto contable *Adjust bad debt*).

2.5. Número de clientes, facturas, productos y países distintos

- **Clientes distintos (CustomerID válidos):** 4.372 clientes únicos (4.338 clientes con compras válidas no canceladas).
- **Facturas distintas (InvoiceNo):** 25.900 facturas totales (22.064 facturas de venta y 3.836 cancelaciones).
- **Productos distintos:** 4.070 códigos únicos (`StockCode`) y 4.223 descripciones distintas (`Description`).
- **Países distintos (Country):** 38 países. Predomina claramente **United Kingdom** con 495.478 líneas (**91,43 %**), seguido a gran distancia por Germany (9.495; 1,75 %), France (8.557; 1,58 %) y EIRE/Irlanda (8.196; 1,51 %).

2.6. Distribución del importe de las transacciones y posibles valores extremos

Calculando el importe de cada línea como `TotalPrice = Quantity * UnitPrice`, observamos una distribución fuertemente asimétrica hacia la derecha con presencia de valores extremos (*outliers*) tanto positivos como negativos:

Variable	Media	Desv. Típica	Mínimo	P25	Mediana (P50)	P75	P99	Máximo
Quantity	9,55	218,08	-80.995	1,00	3,00	10,00	100,00	80.995
UnitPrice (£)	4,61	96,76	-11.062,06	1,25	2,08	4,13	18,00	38.970,00
TotalPrice (£)	17,99	378,81	-168.469,60	3,40	9,75	17,40	180,00	168.469,60

- **Comportamiento habitual:** El 50 % central de las líneas de compra tiene un importe entre **3,40 £ (P25) y 17,40 £ (P75)**, con una mediana de **9,75 £**, y el 99 % de las líneas no supera los 180,00 £.
- **Valores extremos detectados:** Destacan dos pedidos mayoristas extraordinarios que distorsionan la media y la desviación estándar: (1) la factura **581483** (cliente 16446) por **80.995 unidades** de *PAPER CRAFT, LITTLE BIRDIE* (+168.469,60 £), anulada minutos después en la factura **C581484** (-168.469,60 £); y (2) la factura **541431** (cliente 12346) por **74.215 unidades** de *MEDIUM CERAMIC TOP STORAGE JAR* (+77.183,60 £), también cancelada en **C541433** (-77.183,60 £), además de cargos manuales (`StockCode == 'M'` o

'AMAZONFEE') de hasta 38.970 £.

2.7. Pregunta de análisis: ¿Por qué cada fila del archivo representa una línea de factura y no un cliente completo?

Cada fila del archivo original tiene una **granularidad de línea de factura (*order line-item*)** porque registra la adquisición de **un artículo específico (`StockCode`) dentro de un pedido concreto (`InvoiceNo`)** realizado por un cliente (`CustomerID`) en una fecha determinada (`InvoiceDate`).

En una base de datos transaccional de comercio electrónico (OLTP) existe una doble relación jerárquica **1 a muchos (1:N)**:

1. **Un cliente (`CustomerID`) realiza múltiples pedidos (`InvoiceNo`)** en distintas fechas a lo largo del año.
2. **Cada pedido o factura (`InvoiceNo`) contiene varios productos distintos (`StockCode`)** en el carrito, generando una fila independiente por cada referencia comprada en esa factura (por ejemplo, la primera factura `536365` del cliente `17850` ocupa 7 filas, una por cada artículo del pedido, y ese mismo cliente aparece en 312 filas repartidas en 35 facturas).

Conclusión para el modelado: Si aplicáramos K-Means directamente sobre las filas del dataset bruto, estaríamos agrupando *líneas de productos sueltos* y no clientes. Por ello es obligatorio transformar y agregar primero la tabla por `CustomerID` mediante las variables **RFM** (*Recency, Frequency, Monetary*), garantizando que cada fila represente exactamente a un único cliente.