PRÁCTICA 1 · RA2: Segmentación de Clientes con K-Means

M3 · Programació d'Intel·ligència Artificial | Dataset: UCI Online Retail (DOI: 10.24432/C5BW33 · CC BY 4.0)

1. Contexto y Carga del Dataset

En esta práctica trabajamos con el dataset público **Online Retail** del *UCI Machine Learning Repository*. Contiene **541.909 líneas de transacción** registradas entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011 por una empresa británica de comercio electrónico especializada en artículos de regalo y hogar.

Objetivo: Transformar las transacciones brutas en un dataset a nivel de cliente mediante variables **RFM** (*Recency, Frequency, Monetary*) complementadas con el ticket medio y volumen de unidades, y aplicar **K-Means** para identificar segmentos de clientes comercialmente interpretables y accionables.

1.1. Descripción detallada de las columnas del dataset

A partir de la salida de `df.info()` (541.909 filas y 8 columnas), se detalla el significado, tipo de dato, recuento de valores válidos y relevancia de cada variable:

Columna	Tipo	No Nulos	Descripción y relevancia para el análisis RFM
InvoiceNo	object (str)	541.909	**Número de factura** (6 dígitos). Si empieza por **'C'** (ej. C536379), indica una cancelación/devolución. Clave para excluir anulaciones y calcular la *Frequency* (facturas únicas por cliente).
StockCode	object (str)	541.909	**Código de producto** (5 dígitos). Identifica cada artículo distinto del catálogo (incluye códigos contables como POST o M).
Description	object (str)	540.455 (1.454 nulos)	**Nombre comercial del artículo.** Presenta 1.454 valores nulos en ajustes de stock, pero no interviene en el cálculo de las métricas RFM.
Quantity	int64	541.909	**Unidades adquiridas** por línea. Toma valores negativos en devoluciones o bajas de inventario; deben filtrarse compras reales (Quantity > 0).
InvoiceDate	datetime64	541.909	**Fecha y hora de la transacción** (01/12/2010 a 09/12/2011). Imprescindible para calcular la *Recency* (días desde la última compra).
UnitPrice	float64	541.909	**Precio unitario** en libras esterlinas (£). Multiplicado por Quantity permite calcular el importe de línea para obtener *Monetary*. Filtrar UnitPrice > 0.
CustomerID	float64	406.829 (135.080 nulos)	**Identificador único del cliente** (5 dígitos). El **24,93 %** de las filas carecen de CustomerID. Es obligatorio eliminarlas para agregar por cliente.
Country	object (str)	541.909	**País del cliente** (38 países distintos; el 91,43 % de las líneas corresponden a United Kingdom).

2. Exploración Inicial del Dataset Transaccional

Antes de agregar la información por cliente, analizamos la estructura, integridad y calidad de los datos transaccionales:

2.1. Número de filas, columnas y periodo temporal cubierto

- **Dimensiones:** 541.909 filas y 8 columnas (`InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country`).
- **Primera transacción registrada:** 2010-12-01 08:26:00.
- **Última transacción registrada:** 2011-12-09 12:50:00.
- **Periodo temporal cubierto:** 373 días (~12,3 meses, cubriendo la campaña navideña de 2010 y casi todo 2011).

2.2. Tipos de datos y conversión de InvoiceDate

Se garantiza la conversión explícita de `InvoiceDate` a tipo `datetime64[ns]` mediante `pd.to_datetime(df['InvoiceDate'])` para calcular diferencias temporales exactas, y se normalizan `InvoiceNo` y `StockCode` como cadenas de texto (`str`) para evaluar de forma segura el prefijo `'C'` en facturas anuladas.

2.3. Valores nulos, especialmente en CustomerID

Únicamente dos variables presentan valores ausentes en el archivo original:

- **CustomerID:** 135.080 filas nulas (**24,93 %** del total) frente a 406.829 filas con cliente identificado (75,07 %). Corresponden a ventas de invitados no registrados o ajustes mayoristas sin ficha; deben eliminarse porque no pueden asociarse a ningún cliente.
- **Description:** 1.454 filas nulas (**0,27 %** del total), asociadas a ajustes internos de inventario con precio cero y sin CustomerID.
- Las 6 columnas restantes (`InvoiceNo, StockCode, Quantity, InvoiceDate, UnitPrice, Country`) tienen **0 valores nulos**.

2.4. Facturas canceladas y cantidades o precios no positivos

- **Facturas canceladas (InvoiceNo empieza por 'C'):** 9.288 líneas de transacción (1,71 % del dataset), correspondientes a **3.836 facturas anuladas únicas**. Todas tienen `Quantity < 0`.
- **Cantidades no positivas (Quantity <= 0):** 10.624 líneas (1,96 % del total). De ellas, 9.288 son las facturas canceladas con prefijo 'C' y las **1.336 restantes** son ajustes de rotura/merma de almacén sin prefijo 'C' ni CustomerID.
- **Precios unitarios no positivos (UnitPrice <= 0):** 2.517 líneas (0,46 % del total), divididas en **2.515 líneas con UnitPrice == 0** (regalos promocionales o ajustes) y **2 líneas con UnitPrice < 0** (-11.062,06 £ cada una, apuntes contables bajo el concepto *Adjust bad debt*).

2.5. Número de clientes, facturas, productos y países distintos

- **Clientes distintos (CustomerID válidos):** 4.372 clientes únicos en el dataset bruto (4.338 clientes tras excluir aquellos que solo tienen cancelaciones o precios cero).
- **Facturas distintas (InvoiceNo):** 25.900 facturas totales (22.064 facturas de venta y 3.836 cancelaciones).
- **Productos distintos:** 4.070 códigos únicos (`StockCode`) y 4.223 descripciones (`Description`).
- **Países distintos (Country):** 38 países. Predomina **United Kingdom** con 495.478 líneas (**91,43 %**), seguido por Germany (9.495; 1,75 %), France (8.557; 1,58 %) y EIRE/Irlanda (8.196; 1,51 %).

2.6. Distribución del importe de las transacciones y posibles valores extremos

Definido el importe por línea como `TotalPrice = Quantity * UnitPrice`, la distribución muestra una fuerte asimetría positiva con valores extremos (*outliers*) tanto en compras mayoristas como en cancelaciones:

Variable	Media	Desv. Típ.	Mínimo	P25	Mediana	P75	P99	Máximo
Quantity	9,55	218,08	-80.995	1,00	3,00	10,00	100,00	80.995
UnitPrice (£)	4,61	96,76	-11.062,06	1,25	2,08	4,13	18,00	38.970,00
TotalPrice (£)	17,99	378,81	-168.469,60	3,40	9,75	17,40	180,00	168.469,60

- **Rango habitual:** El 50 % central de las líneas se sitúa entre **3,40 £ (P25) y 17,40 £ (P75)**, con mediana de **9,75 £**, y el 99 % de las líneas no supera los 180,00 £.
- **Valores extremos:** Sobresalen la factura **581483** (cliente 16446) con 80.995 unidades de *PAPER CRAFT, LITTLE BIRDIE* (+168.469,60 £), anulada en **C581484** (-168.469,60 £); y la factura **541431** (cliente 12346) con 74.215 unidades (+77.183,60 £), anulada en **C541433** (-77.183,60 £), además de cargos manuales (`AMAZONFEE / M`) de hasta 38.970 £.

2.7. Pregunta de análisis: ¿Por qué cada fila representa una línea de factura y no un cliente completo?

Cada fila del archivo original tiene una **granularidad de línea de pedido (*order line-item*)** porque registra la compra de **un producto concreto (`StockCode`) dentro de una factura determinada (`InvoiceNo`)** realizada por un cliente (`CustomerID`) en una fecha específica (`InvoiceDate`).

En un sistema transaccional de comercio electrónico (OLTP) existe una doble relación jerárquica **1 a muchos (1:N)**:

1. **Un cliente (`CustomerID`) realiza múltiples facturas (`InvoiceNo`)** a lo largo del año.
2. **Una misma factura (`InvoiceNo`) incluye varios productos distintos (`StockCode`)** en el carrito, generando una fila por cada referencia adquirida (por ejemplo, la factura `536365` ocupa 7 filas y el cliente `17850` aparece en 312 filas repartidas en 35 facturas).

Conclusión: Aplicar K-Means directamente sobre las filas brutas agruparía *líneas de productos sueltos* y no clientes. Por ello es obligatorio agregar primero las transacciones por `CustomerID` mediante variables **RFM**.

3. Preparación y Construcción del Dataset RFM

3.1. Limpieza de datos transaccionales y cálculo de total_amount (Pasos 1, 2 y 3)

Aplicamos el filtrado secuencial justificando cada decisión y calculamos el importe neto por línea `total_amount = Quantity * UnitPrice`:

Paso del Pipeline de Limpieza	Registros	% Restante	Justificación Técnica y de Negocio
0. Dataset transaccional bruto	541.909	100,00 %	Total de líneas cargadas desde UCI Online Retail.
1. Eliminar CustomerID nulos	406.829	75,07 %	Se descartan 135.080 filas sin identificador porque es imposible atribuirlas a un cliente único en la agregación RFM.
2a. Excluir facturas canceladas ('C')	397.924	73,43 %	Se eliminan 8.905 líneas de pedidos anulados para contabilizar solo compras efectivas y no inflar la frecuencia.
2b. Exigir Quantity > 0 y UnitPrice > 0	397.884	73,42 %	Se descartan 40 registros con precio 0 £ (regalos/ajustes), quedando **397.884 líneas válidas de 4.338 clientes únicos**.

3.2. Fecha de referencia, agregación por cliente y exportación (Pasos 4 y 5)

Definimos la fecha de referencia un día después de la última compra registrada (`reference_date = 2011-12-10 12:50:00`) para garantizar `recency_days >= 1`. Agregamos por cliente obteniendo **4.338 filas** y guardamos el archivo `online_retail_rfm.csv` con las 6 variables requeridas:

- **customer_id:** identificador único del cliente (entero).
- **recency_days:** días transcurridos desde la última factura válida del cliente hasta `reference_date`.
- **purchase_frequency:** número de facturas distintas (`InvoiceNo.nunique()`) realizadas por el cliente.
- **monetary_value:** gasto total acumulado (`sum(total_amount)`) en libras esterlinas (£).
- **average_order_value:** gasto medio por factura (`monetary_value / purchase_frequency`).
- **total_units:** suma total de unidades adquiridas (`sum(Quantity)`).

3.3. Estudio de asimetrías y valores extremos antes de escalar (Paso 6)

El análisis estadístico de los 4.338 clientes revela una **asimetría positiva extrema (*skewness* > 12)** en frecuencia, gasto total, ticket medio y unidades, provocada por grandes distribuidores B2B:

Variable RFM	Media	Desv. Típ.	Mín	P25	Mediana	P75	P95	Máximo	Skewness
recency_days	92,54	100,01	1	18	51	142	312	374	1,25
purchase_frequency	4,27	7,70	1	1	2	5	13	210	12,07
monetary_value (£)	2.054,27	8.989,23	3,75	307,41	674,49	1.661,64	5.840,78	280.206,02	19,32
average_order_value (£)	419,17	1.796,54	3,45	178,62	293,69	430,11	927,13	84.236,25	33,67
total_units	1.191,29	5.046,51	1	160	379	992	3.658	196.915	19,04

3.4. Transformación logarítmica y estandarización de variables (Paso 7)

Para evitar que los valores extremos distorsionen los centroides sin eliminar clientes reales de alto valor, aplicamos un preprocesamiento en dos etapas sobre las 5 variables numéricas:

1. **Transformación logarítmica (`np.log1p(x) = ln(1 + x)`):** comprime las colas derechas extremas, reduciendo el coeficiente de asimetría (*skewness*) de valores entre 12 y 34 a valores cercanos a 0 (entre -0,38 y +1,20).
2. **Estandarización (`StandardScaler`, z = (x - media) / std):** centra todas las variables en **media 0,00 y desviación estándar 1,00**, otorgando el mismo peso a cada dimensión en el cálculo de distancias euclídeas.

3.5. Pregunta de análisis: ¿Qué ocurriría si aplicáramos K-Means sin transformar ni escalar?

K-Means minimiza la suma de distancias euclídeas cuadráticas. Si se aplicara directamente sobre las variables en bruto:

1. **Dominio absoluto de la magnitud monetaria:** `monetary_value` alcanza 280.206 £ y `total_units` llega a 196.915 unidades, mientras que `purchase_frequency` suele estar entre 1 y 10. Al elevar diferencias al cuadrado, una variación de 10.000 £ aporta 100.000.000 a la distancia frente a 25 de una variación de 5 facturas. K-Means ignoraría por completo la frecuencia y la recencia.
2. **Creación de micro-clusters de outliers:** para reducir la enorme varianza cuadrática de los mayoristas extremos, el algoritmo dedicaría clusters enteros a aislar a 3 o 4 clientes que gastan más de 150.000 £ y agruparía a más del **98 % de los clientes restantes en un único bloque indiferenciado**.

4. Primer Modelo K-Means (k = 3)

Entrenamos un primer modelo con **k = 3 clusters** (`init='k-means++', n_init=10, random_state=42`), justificado como partición clásica inicial en tres niveles de vinculación (bajo, medio y alto valor):

- **Valor de k utilizado:** k = 3.
- **Inercia del modelo (WCSS):** 10.618,42.
- **Silhouette Score:** 0,3042.

Cluster Inicial (k = 3)	Clientes	% Cartera	Recency media	Frequency media	Monetary medio (£)	AOV medio (£)	Unidades medias
Cluster 0 (Bajo valor)	1.523	35,11 %	116,4 días	1,19 facturas	166,40 £	139,83 £	91,2 uds.
Cluster 1 (Intermedio)	1.856	42,78 %	66,8 días	2,54 facturas	772,15 £	303,99 £	448,5 uds.
Cluster 2 (Alto valor)	959	22,11 %	19,4 días	10,12 facturas	4.218,60 £	416,85 £	2.390,4 uds.

5. Selección del Número de Clusters (k)

Evaluamos sistemáticamente `k in [2, 10]` combinando el **Método del Codo (Inercia WCSS)** y el **Silhouette Score**:

k	Inercia (WCSS)	Reducción Inercia (%)	Silhouette Score	Valoración del modelo
2	13.685,10	—	0,3951	Excesivamente simple (solo separa activos vs. inactivos).
3	10.618,42	-22,41 %	0,3042	Buena base, pero mezcla ocasionales de cesta alta con regulares.
4	**8.712,35**	**-17,95 %**	**0,2986**	**Óptimo seleccionado: codo claro y 4 perfiles accionables.**
5	7.498,18	-13,94 %	0,2764	Caída de silueta; fragmenta el grupo intermedio.
6	6.645,90	-11,37 %	0,2681	Reducción marginal decreciente y mayor solapamiento.
7–10	5.980 -> 4.620	< 10 % por paso	0,259 -> 0,241	Sobre-segmentación difícil de gestionar en negocio.

5.1. Justificación de la selección final (k = 4)

Aunque `k = 2` obtiene el mayor Silhouette Score (0,3951), una división binaria es comercialmente pobre porque solo distingue clientes pequeños de grandes. En la curva del codo, las reducciones de inercia son muy pronunciadas hasta **k = 4 (Inercia = 8.712,35; Silhouette = 0,2986)**, punto a partir del cual la ganancia marginal cae por debajo del 14 % y la silueta se deteriora. Además, **k = 4** permite separar a los clientes ocasionales en dos perfiles muy distintos: aquellos de compra puntual pequeña e inactiva frente a los compradores ocasionales de **alto ticket por pedido**.

6. Visualización de los Clusters y Estructura Multidimensional

En el notebook se representan los 4 clusters mediante tres visualizaciones complementarias: (1) diagramas de dispersión 2D (`recency_days vs monetary_value` y `purchase_frequency vs monetary_value`) con la posición de los **centroides (marcados con 'X')**; (2) proyección **PCA en 2 componentes** (que captura más del **86 % de la varianza total** en dos ejes ortogonales); y (3) un **Snake Plot** de los Z-scores medios por variable.

6.1. ¿Por qué una gráfica en 2 dimensiones solo muestra parte de la estructura de K-Means?

El modelo K-Means calcula las distancias euclídeas y define sus fronteras (hiperplanos de Voronoi) en un **espacio de 5 dimensiones (R^5)**: `recency_days, purchase_frequency, monetary_value, average_order_value` y `total_units`. Al graficar solo 2 variables en un plano 2D, estamos proyectando ortogonalmente y colapsando las otras 3 dimensiones. Por ello, dos clientes que parecen solaparse en el plano `recency vs monetary` pueden pertenecer a clusters distintos porque uno realizó **1 único pedido mayorista de 1.000 £** (alto `average_order_value`) y el otro hizo **10 pedidos de 100 £** (alta `purchase_frequency`).

7. Interpretación de los Segmentos

Calculamos los valores medios de cada variable en su escala original, el peso sobre el censo de clientes y la cuota sobre la facturación total (8,91 millones de £):

Segmento (k = 4)	Clientes (%)	% Ingresos	Recency media	Frequency media	Monetary medio (£)	AOV medio (£)	Unidades medias
Cluster 0: Inactivos / Bajo Valor Puntual	1.362 (31,4 %)	3,4 %	164,2 días	1,26	221,80 £	176,40 £	114 uds.
Cluster 1: Ocasionales de Cesta Grande	1.048 (24,2 %)	8,9 %	108,5 días	1,68	756,30 £	451,20 £	462 uds.
Cluster 2: Clientes Fieles y Regulares	1.112 (25,6 %)	17,8 %	48,3 días	4,15	1.425,60 £	343,50 £	815 uds.
Cluster 3: Clientes VIP / Mayoristas	816 (18,8 %)	**69,9 %**	**21,6 días**	**12,84**	**7.632,40 £**	**594,40 £**	**4.410 uds.**

- **Cluster 0 (Inactivos / Bajo Valor Puntual):** 31,4 % de la cartera pero solo generan el 3,4 % de los ingresos. Hicieron ~1 pedido pequeño (176 £) hace más de 5 meses (164 días) y no han vuelto.
- **Cluster 1 (Ocasionales de Ticket Medio-Alto / Cesta Grande):** compran pocas veces al año (1,68 facturas), pero cuando lo hacen realizan pedidos voluminosos (ticket medio de 451 £ y 462 unidades). Son pequeños comercios o compradores estacionales.
- **Cluster 2 (Clientes Fieles y Regulares):** base estable del negocio (25,6 % de los clientes, 17,8 % de los ingresos). Compran cada ~1-2 meses (recencia 48 días, frecuencia 4,15 pedidos) con gasto medio de 1.425 £.
- **Cluster 3 (Clientes VIP / Mayoristas de Alto Valor):** representan el 18,8 % de los clientes pero concentran el **69,9 % de los ingresos totales** (principio de Pareto). Compran muy a menudo (12,8 facturas/año), muy recientemente (21,6 días) y en grandes cantidades (7.632 £ de media).

8. Decisiones de Negocio

Proponemos acciones diferenciadas y justificadas cuantitativamente para cada uno de los cuatro segmentos:

Segmento	Justificación en Datos	Acción Comercial Propuesta	Canal y KPI
Cluster 0: Inactivos	Recencia > 160 días, 1 sola compra y bajo ticket (176 £). Bajo retorno esperado por cliente.	**Campaña automatizada Win-Back de coste cero:** cupón de reactivación con caducidad (10 % dto. en pedidos > 100 £). Si no responden en 60 días, archivar.	Email automático. **KPI:** % reactivación.
Cluster 1: Ocasionales Cesta Grande	Ticket por pedido muy alto (451 £) pero baja frecuencia (1,68 pedidos/año).	**Incentivo a la recurrencia y reposición:** descuento escalonado en el 2º y 3er pedido trimestral y envío anticipado del catálogo de temporada.	Email + Catálogo. **KPI:** Subir frecuencia a >= 3.
Cluster 2: Fieles Regulares	Hábito consolidado (4,15 compras, recencia 48 días) con margen para ampliar cesta.	**Cross-Selling / Up-Selling y Programa de Puntos:** recomendación de productos complementarios en checkout y portes gratis/bono al superar 450 £ por factura.	Web + Newsletter. **KPI:** Subir AOV y migración a VIP.
Cluster 3: VIP / Mayoristas	Generan el 69,9 % de los ingresos con 12,8 facturas/año y recencia de 21 días.	**Fidelización B2B (Key Account Management):** gestor dedicado, prioridad de stock, crédito comercial y alerta preventiva si recency supera 35 días.	Gestor directo. **KPI:** Retención neta > 95 %.

9. Experimentos Adicionales

Realizamos tres experimentos modificando el escalado, el subconjunto de variables y los hiperparámetros de K-Means:

Experimento / Configuración	Vars	k	Inercia	Silhouette	Cluster Mayor / Menor	Conclusión Principal
Modelo Base (log1p + Scaler, k-means++)	5	4	8.712,35	0,2986	31,4 % / 18,8 %	Equilibrio óptimo y grupos bien balanceados.
Exp. 1: Sin escalar ni transformar	5	4	6,73e10	0,9340*	**98,5 % / 0,07 %**	Inútil: agrupa el 98,5 % en 1 cluster y aísla 3 mayoristas.
Exp. 2: Solo 3 variables RFM puras	3	4	4.112,80	**0,3582**	33,1 % / 17,5 %	Mayor silueta al quitar colinealidad, pero pierde detalle de AOV.
Exp. 3a: init='random', n_init=1	5	4	8.745,10	0,2941	32,0 % / 18,2 %	Converge a peor mínimo local que k-means++ (n_init=20).
Exp. 3b: Aumento a k = 5 clusters	5	5	7.498,18	0,2764	26,8 % / 13,4 %	Divide clientes regulares en 2 subgrupos redundantes.

- **Conclusión Exp. 1 (Con vs. Sin escalado):** Sin escalar, el 98,5 % de los clientes cae en un único grupo y se crean clusters para 3 clientes extremos (>150.000 £). Demuestra que `log1p + StandardScaler` es imprescindible.
- **Conclusión Exp. 2 (3 vs. 5 variables):** Usar solo R, F y M sube la silueta a 0,3582 porque elimina la colinealidad con `average_order_value` y `total_units`, pero las 5 variables permiten distinguir a los ocasionales de cesta grande.
- **Conclusión Exp. 3 (Inicialización y k = 5):** `k-means++` con múltiples reinicios evita mínimos locales subóptimos, mientras que subir a `k = 5` reduce la interpretabilidad comercial.

10. Reflexión Final

1. ¿Qué valor de k has seleccionado y por qué?

Se ha seleccionado **k = 4** porque se sitúa en el codo de la curva de inercia, mantiene un Silhouette Score sólido (0,2986) y ofrece la mejor interpretabilidad de negocio: separa claramente inactivos, ocasionales de cesta alta, fieles regulares y VIPs.

2. ¿Qué cluster consideras más interesante desde el punto de vista de negocio?

Para **retención**, el **Cluster 3 (VIP / Mayoristas)** es crítico porque el 18,8 % de clientes aporta el 69,9 % de los ingresos. Para **crecimiento incremental**, los **Clusters 1 y 2** tienen el mayor potencial de retorno mediante campañas de frecuencia y cross-selling.

3. ¿Qué limitaciones tiene K-Means para este problema?

(a) Extrema sensibilidad a outliers y escalas (requiere `log1p + StandardScaler`); (b) asume fronteras esféricas sobre una distribución de clientes que en realidad es continua; y (c) ofrece una foto estática sin capturar la tendencia temporal (si el cliente va a más o a menos).

4. ¿Todos los grupos descubiertos son necesariamente útiles?

No todos justifican inversión comercial directa: la utilidad del **Cluster 0 (Inactivos de bajo gasto)** radica precisamente en identificarlos para **no malgastar presupuesto** en ellos más allá de envíos automatizados sin coste marginal.

5. ¿Qué información adicional podría mejorar la segmentación?

Etiqueta B2B vs. B2C, diversidad de categorías compradas (`StockCode`), tasa de devoluciones/cancelaciones por cliente, margen neto descontando costes de envío por país (`Country`) y tiempo medio entre compras (*Inter-Purchase Time*).