PRÁCTICA 2 · RA2

Decision Tree y Random Forest

Predicción de intención de compra con datos reales

M3 · Programació d'Intel·ligència Artificial

RA2 · Implementación y evaluación de modelos de IA

Práctica individual · Google Colab

Curso de Especialización en Inteligencia Artificial y Big Data

Rubén Gasque Todolí

Monlau

Índice

Contexto	3
Exploración inicial	3
Preparación	3
Decision Tree	3
Control de complejidad y overfitting	4
Regiones de decisión	4
Random Forest	4
Evaluación	4
Importancia de variables	4
Comparación final	5
Análisis de errores	5
Entrega	5
Criterios de evaluación	5

1. Contexto

En esta práctica utilizarás el dataset público Online Shoppers Purchasing Intention del UCI Machine Learning Repository para predecir si una sesión de comercio electrónico termina en compra.

Fuente: Sakar y Kastro, UCI Machine Learning Repository, DOI 10.24432/C5F88Q. Licencia CC BY 4.0.

El archivo `online_shoppers_intention.csv` contiene 12.330 sesiones independientes, sin valores nulos. La variable objetivo es `Revenue`: aproximadamente el 15,5% de las sesiones terminan en compra y el 84,5% no lo hacen.

Las variables predictoras incluyen:

- páginas administrativas, informativas y de producto, junto con su duración;
- `BounceRates`, `ExitRates` y `PageValues`;
- proximidad a fechas especiales mediante `SpecialDay`;
- mes, sistema operativo, navegador, región y tipo de tráfico;
- tipo de visitante y acceso durante el fin de semana.

Se compararán dos estrategias: un Decision Tree interpretable y un Random Forest más robusto.

2. Exploración inicial

Analiza el dataset antes de entrenar los modelos.

Como mínimo, estudia:

- dimensiones, tipos y ausencia de valores nulos;
- distribución de la variable objetivo `Revenue`;
- distribución y posibles valores extremos de las variables numéricas;
- frecuencias de las variables categóricas;
- relaciones entre duración, páginas visitadas, tasas de rebote y compra;
- diferencias entre sesiones con y sin compra.

Pregunta de análisis: ¿por qué una accuracy alta puede resultar engañosa si solo el 15,5% de las sesiones termina en compra?

3. Preparación

Prepara los datos mediante un proceso reproducible:

1. separa `Revenue` como variable objetivo y utiliza el resto como variables predictoras;
2. identifica variables numéricas, booleanas y categóricas;
3. codifica correctamente variables como `Month` y `VisitorType`;
4. divide los datos en entrenamiento y test mediante una partición estratificada;
5. fija un `random_state`;
6. aplica las transformaciones aprendidas únicamente sobre el conjunto de entrenamiento.

Explica por qué Decision Tree y Random Forest no necesitan escalado para realizar sus divisiones. Utiliza las mismas particiones y el mismo preprocesamiento al comparar ambos modelos.

Debido al desequilibrio de clases, no bases la evaluación únicamente en accuracy. Considera si es necesario utilizar `class_weight` y justifica la decisión.

Pregunta de análisis: ¿qué fuga de información se produciría si ajustáramos la codificación o cualquier transformación utilizando también el conjunto de test?

4. Decision Tree

Entrena un primer árbol de decisión.

Como mínimo deberás:

- definir el modelo;
- entrenarlo;
- generar predicciones;
- calcular métricas;

- visualizar el árbol.

La visualización deberá permitir interpretar algunas reglas del modelo.

Por ejemplo:

> Si el número de visitas es alto y existen compras previas, la probabilidad de compra puede aumentar.

No debes inventar reglas: deberán extraerse del árbol realmente entrenado.

5. Control de complejidad y overfitting

Entrena varios árboles modificando, al menos, uno de estos hiperparámetros:

- `max_depth`;
- `min_samples_split`;
- `min_samples_leaf`.

Compara el rendimiento en entrenamiento y test.

Pregunta de análisis: ¿qué señales indican que un árbol está sobreajustando?

6. Regiones de decisión

Selecciona dos variables adecuadas y entrena un árbol utilizando únicamente esas dos variables para crear una representación bidimensional de las regiones de decisión.

Explica la relación entre:

- las divisiones del espacio;
- las condiciones if/then del árbol;
- las ramas observadas en la visualización del modelo.

7. Random Forest

Entrena un Random Forest utilizando las mismas variables y la misma separación de datos.

Deberás indicar y justificar, al menos:

- número de árboles;
- profundidad máxima, si se limita;
- `random_state`.

Evalúa el modelo utilizando las mismas métricas que el árbol individual.

8. Evaluación

Para ambos modelos calcula como mínimo:

- accuracy;
- precision;
- recall;
- F1-score;
- matriz de confusión.

Resume los resultados en una tabla comparativa.

9. Importancia de variables

Obtén la importancia de las variables del Random Forest y represéntala gráficamente.

Responde:

1. ¿qué variables han sido más importantes?
2. ¿coincide con lo que esperabas al explorar los datos?
3. ¿una importancia alta implica causalidad? Justifica la respuesta.

10. Comparación final

Compara Decision Tree y Random Forest considerando:

- rendimiento;
- interpretabilidad;
- estabilidad;
- riesgo de overfitting;
- facilidad para explicar una predicción;
- coste computacional.

No se valorará únicamente qué modelo obtiene una métrica más alta, sino la capacidad de justificar cuándo sería preferible utilizar cada uno.

11. Análisis de errores

Selecciona al menos cinco ejemplos mal clasificados por alguno de los modelos.

Para cada caso muestra:

- valores de entrada;
- clase real;
- predicción;
- una posible explicación del error.

12. Entrega

Se entregará un único notebook `.ipynb`, ejecutado y reproducible, que incluya:

1. exploración;
2. preparación de datos;
3. Decision Tree;
4. análisis de complejidad;
5. visualización del árbol;
6. regiones de decisión;
7. Random Forest;
8. métricas y matrices de confusión;
9. importancia de variables;
10. análisis de errores;
11. comparación final.

13. Criterios de evaluación

Apartado	Peso
Exploración y preparación de datos	10%
Decision Tree e interpretación	20%
Control de complejidad y overfitting	15%
Random Forest	20%
Evaluación y comparación de métricas	15%
Importancia de variables y análisis de errores	10%
Conclusiones y justificación técnica	10%
Total	100%