PRÁCTICA 3 · RA1

Crisis en ShopData

Investiga el fallo y diseña la nueva arquitectura Big Data

M4 · Sistemes de Big Data
RA1 · Calidad, procesamiento, escalabilidad y diseño

Guía rápida

Duración orientativa 8-10 horas	Herramientas Python 3 · Pandas · Colab o Jupyter · Herramienta de diagramas	Entrega Notebook · Propuesta técnica PDF · Diagrama · ZIP

RUTA DE TRABAJO

Incidente → Latencia y calidad → Escala → Arquitectura → Coste → Propuesta

CHECKLIST ANTES DE ENTREGAR

- [ ] El diagnóstico utiliza evidencias obtenidas mediante código.
- [ ] La capacidad se comprueba para carga media y picos.
- [ ] La arquitectura cumple el presupuesto de 7.000 €/mes.
- [ ] La propuesta y el diagrama justifican cada decisión.

Rubén Gasque Todolí

. Mapa de la práctica

Numeración actualizada para la versión multifuente integrada.

1. La situación	3	10. Fase 6: construye tu arquitectura	8
2. Objetivos de aprendizaje	4	11. El presupuesto	9
3. Criterios de evaluación relacionados	4	12. Fase 7: propuesta técnica	9
4. Datos disponibles y modelo lógico	4	12.1. Comprueba la capacidad	9
5. Fase 1: investigación multifuente	5	13. Fase 8: diagrama	9
5.1. ¿Qué datos son sospechosos?	5	14. Fase 9: propuesta a dirección	10
6. Fase 2: alertas y latencia total	6	15. Situación final	10
6.1. Reconstrucción de la crisis	6	16. Requisitos técnicos	10
7. Fase 3: diagnóstico	6	17. Reproducibilidad	11
7.1. Métricas de calidad	7	18. Entrega	11
8. Fase 4: el sistema va a crecer	7	19. Evaluación	12
8.1. Escenario de pico	7		
9. Fase 5: clasifica las necesidades	8		

1. La situación

ShopData S.L. utiliza cientos de sensores conectados en sus almacenes para controlar:

- temperatura;
- humedad;
- consumo energético;
- apertura de puertas;
- estado de maquinaria;
- incidencias operativas.

Durante los últimos días se han producido diferentes problemas.
En uno de los almacenes, una cámara frigorífica permaneció durante demasiado tiempo fuera de su rango seguro de temperatura.
La alerta llegó al sistema, pero cuando el equipo responsable recibió la notificación ya era demasiado tarde.
Parte de la mercancía tuvo que ser retirada.
Además, el equipo técnico sospecha que existen:

- sensores que generan valores incorrectos;
- eventos duplicados;
- eventos que llegan con demasiado retraso;
- dispositivos con configuraciones incoherentes;
- diferencias importantes entre almacenes.

La situación se complica porque ShopData está preparando una ampliación de su infraestructura.
Actualmente dispone de aproximadamente:

500 dispositivos

pero durante los próximos meses quiere superar:

30.000 dispositivos

MISIÓN
Tu equipo ha sido contratado para investigar qué está ocurriendo y proponer una nueva arquitectura de datos.
Deberás:

1. investigar los eventos mediante Python;
2. identificar los principales problemas;
3. comprobar si ShopData puede cumplir sus requisitos actuales;
4. estimar qué ocurrirá cuando el sistema crezca;
5. diseñar una arquitectura adecuada;
6. construir una solución que no supere el presupuesto disponible.

4. Datos disponibles y modelo lógico

El análisis se realiza exclusivamente con las cinco fuentes del paquete.

Antes de combinar datos, inspecciona claves, nulos, duplicados, tipos y cardinalidades. Las relaciones son expectativas del negocio, no garantías de integridad del dato bruto.

Archivo	Contenido y función
events.csv	Eventos brutos: identificador, tiempos, dispositivo, almacén declarado, medida, unidad y estado.
devices.csv	Maestro de dispositivos: ubicación oficial, tipo, unidad, límites físicos y umbrales de alerta.
warehouses.csv	Identificación y características de los almacenes.
alerts.csv	Procesamiento y notificación de alertas relacionadas mediante event_id.
incidents.csv	Anotaciones operativas e impacto empresarial; se relacionan por almacén, zona y periodo.

Modelo lógico esperado

warehouses 1:N devices · devices 1:N events · events 1:N alerts · warehouses 1:N incidents

No hagas un join 1:N sin comprobar si multiplicará eventos. Usa devices.warehouse_id como asignación oficial y contrástala con events.warehouse_id.

Fase 1 ampliada

- Describe las cinco fuentes y dibuja un esquema lógico sencillo.
- Comprueba PK/FK, nulos, duplicados y cardinalidad antes de cada merge.
- Construye el dataset de análisis sin multiplicar eventos.

Reglas de interpretación

- Normaliza únicamente unidades convertibles justificadas, como F a C o W a kW.
- Conserva el dato bruto y transforma mediante código.
- Consulta DICCIONARIO_DATOS.md para límites y umbrales.

- número de eventos;
- número de dispositivos;
- número de almacenes;
- periodo temporal;
- tipos de evento;
- tipos de datos;
- valores ausentes;
- posibles duplicados;
- distribución de los valores.

Puedes utilizar funciones como:

```
df.shape
df.info()
df.describe()
df.isna().sum()
df.nunique()
df.duplicated().sum()
```

No te limites a mostrar los resultados.
Debes interpretarlos.

5.1. ¿Qué datos son sospechosos?

Investiga posibles problemas relacionados con:

- valores ausentes;
- identificadores repetidos;
- temperaturas imposibles;
- humedades fuera de rango;
- consumos negativos;
- unidades incorrectas;
- estados incompatibles;
- dispositivos asociados de forma incoherente a almacenes;
- cualquier otro patrón que consideres sospechoso.

Define mediante código las reglas utilizadas.
Por ejemplo:

```
temperature_mask = (
    (df["event_type"] == "temperature")
    & ~df["value"].between(-30, 60)
)
```

Los límites anteriores son únicamente orientativos.
Deberás justificar las reglas utilizadas.

6. Fase 2: ¿las alertas llegan a tiempo?

Uno de los principales problemas reportados por ShopData es el retraso en la recepción de eventos.
Convierte correctamente:

6. Fase 2: alertas y latencia total

El requisito crítico es llegar al responsable en menos de 10 segundos.

Medida	Cálculo	Qué representa
Ingesta	received_at - timestamp	Llegada del evento a la plataforma
Procesamiento	processed_at - received_at	Tratamiento y creación de la alerta
Notificación	notified_at - processed_at	Envío al canal correspondiente
Total	notified_at - timestamp	Tiempo completo hasta el responsable

La regla de los 10 segundos

Se aplica a la latencia total hasta la notificación de alertas relevantes. Un evento crítico sin alerta o sin notificación no cuenta como cumplimiento. Informa también su proporción.

Análisis mínimo

- Porcentaje de eventos recibidos tarde.
- Cobertura de alertas para eventos críticos.
- Porcentaje notificado en menos de 10 segundos.
- Media, mediana, p95, p99, máximo y peores casos.
- Separación del retraso entre ingesta, procesamiento y notificación.

Reconstrucción de la crisis

- Localiza la primera lectura anómala conocida.
- Relaciona sensores próximos, llegada de eventos y alertas.
- Contrasta al menos una anotación de incidents.csv con telemetría y alertas.
- Diferencia evidencia observada, asociación e hipótesis causal.

Identificación de eventos críticos: compara el estado declarado con los umbrales del maestro después de normalizar unidades. Explica los casos dudosos y las decisiones sobre alertas repetidas.

- **Importante**;
- **Informativo**.

La gravedad debe justificarse según su impacto.
Por ejemplo, una descripción ausente y una alerta de temperatura recibida con 15 minutos de retraso no tienen la misma importancia.

7.1. Métricas de calidad

Calcula una medida razonada para:

- completitud;
- unicidad;
- validez;
- consistencia;
- actualidad.

Presenta una tabla final.

Dimensión	Resultado
Completitud	XX.X %
Unicidad	XX.X %
Validez	XX.X %
Consistencia	XX.X %
Actualidad	XX.X %

Debes explicar cómo has calculado cada dimensión.
No existe necesariamente una única fórmula válida para todos los problemas.

8. Fase 4: el sistema va a crecer

Actualmente existen:

500 dispositivos

pero el nuevo despliegue contempla:

30.000 dispositivos

Supón inicialmente que cada dispositivo genera:

1 evento cada 10 segundos

Calcula:

1. eventos por segundo con 500 dispositivos;
2. eventos por segundo con 30.000 dispositivos;
3. eventos diarios en ambos escenarios;
4. incremento relativo del volumen.

Utiliza:

$$events_per_second = \frac{devices}{10}$$

8.1. Escenario de pico

Durante una incidencia, algunos dispositivos pueden aumentar temporalmente la frecuencia hasta:

1 evento cada segundo

Supón que esto ocurre simultáneamente en el 20 % de los dispositivos.
Calcula el volumen aproximado de eventos por segundo durante este pico.

La arquitectura deberá diseñarse pensando también en los picos de carga, no únicamente en el promedio.

9. Fase 5: clasifica las necesidades

ShopData necesita resolver los siguientes casos:

Necesidad	Requisito
Alertas críticas	Menos de 10 segundos.
Dashboard operativo	Actualización cada 5 minutos.
Informe energético	Disponible cada mañana antes de las 08:00.
Análisis histórico	Consultas sobre los últimos 5 años.
Mantenimiento predictivo	Reentrenamiento periódico utilizando históricos.

Para cada necesidad decide entre:

- batch;
- microbatch;
- streaming.

Justifica cada elección.

10. Fase 6: construye tu arquitectura

ShopData no quiere comprar una solución cerrada.
Debes construir una arquitectura seleccionando componentes del siguiente catálogo.
Los nombres y costes son ficticios y se han simplificado expresamente para la práctica.

Ingesta de eventos

Componente	Capacidad	Coste/mes	Características
Event Gateway Basic	1.000 eventos/s	500 €	Una única instancia.
Event Gateway HA	8.000 eventos/s	1.500 €	Redundancia y alta disponibilidad.
Event Gateway Pro	25.000 eventos/s	2.900 €	Alta capacidad y redundancia.

Procesamiento

Componente	Capacidad	Coste/mes	Uso
Batch Small	10 M eventos/día	400 €	Procesos periódicos pequeños.
Batch Scalable	400 M eventos/día	1.300 €	Procesamiento histórico de gran volumen.
Streaming Basic	1.500 eventos/s	900 €	Procesamiento continuo básico.
Streaming Scalable	10.000 eventos/s	2.400 €	Procesamiento continuo escalable.

Almacenamiento

Componente	Capacidad	Coste/mes	Uso
Hot Storage	10 TB	950 €	Datos recientes y consultas frecuentes.
Warm Storage	50 TB	650 €	Datos de uso ocasional.
Cold Storage	200 TB	300 €	Históricos y archivado.

Explotación y disponibilidad

11. El presupuesto

Dirección establece un presupuesto máximo de:

7.000 €/mes

Tu arquitectura no podrá superar este límite.

No debes seleccionar simplemente los componentes más caros.
Debes construir la solución más razonable capaz de cumplir los requisitos del negocio.

Componente	Coste/mes	Función
Dashboard Batch	250 €	Actualización cada 15 minutos o más.
Dashboard Near Real-Time	600 €	Actualización aproximadamente cada 1–5 minutos.
Alert Manager	400 €	Generación y envío de alertas.
Redundancy Pack	900 €	Añade redundancia a componentes críticos compatibles.
Monitoring Pack	350 €	Monitorización, métricas y alertas de infraestructura.

Componente	Coste	Motivo
—	—	—

12. Fase 7: propuesta técnica

Selecciona los componentes que utilizarías.
Crea una tabla:
Calcula:

$$Coste_{mensual} = \sum Coste_{componentes}$$

y:

$$Coste_{anual} = Coste_{mensual} \times 12$$

Comprueba que:

$$Coste_{mensual} \leq 7{,}000$$

12.1. Comprueba la capacidad

No basta con cumplir el presupuesto.
Debes demostrar que los componentes seleccionados soportan:

- el volumen medio esperado;
- el escenario de pico;
- los requisitos de latencia;
- el almacenamiento necesario;
- los diferentes tipos de procesamiento.

Si algún componente no tiene capacidad suficiente, la arquitectura deberá modificarse.

13. Fase 8: diagrama

Representa gráficamente la arquitectura propuesta.
El diagrama deberá mostrar como mínimo:

Sensores → Ingesta → Procesamiento → Almacenamiento

y las salidas hacia:

- alertas;
- dashboard;
- informes batch;
- análisis histórico.

Si utilizas diferentes caminos para tiempo real e histórico, deberán distinguirse claramente.
Puedes utilizar:

- draw.io;
- Mermaid;
- Canva;
- PowerPoint;
- otra herramienta equivalente.

14. Fase 9: propuesta a dirección

Entrega una breve propuesta técnica dirigida a la dirección de ShopData.
Debe responder claramente:

1. ¿Qué está fallando actualmente?
2. ¿Qué evidencia has encontrado en los datos?
3. ¿Cumple actualmente ShopData el requisito de alertas en menos de 10 segundos?
4. ¿Qué ocurrirá cuando el sistema pase a 30.000 dispositivos?
5. ¿Qué arquitectura propones?
6. ¿Cuánto cuesta?
7. ¿Qué requisitos cumple?
8. ¿Qué limitaciones mantiene?

15. Situación final

Dirección plantea una última pregunta:

> "Si aumentamos el presupuesto hasta 15.000 € al mes, ¿deberíamos sustituir inmedia-

Una arquitectura técnicamente más potente no es necesariamente una arquitectura mejor.
La solución debe juzgarse según los requisitos que realmente necesita satisfacer.

16. Requisitos técnicos

La solución debe ser reproducible sin desplegar infraestructura real.

Herramientas permitidas

- Python 3 y Pandas.
- Jupyter Notebook o Google Colab.
- Herramienta de diagramas de libre elección.

17. Reproducibilidad

- El notebook debe ejecutarse únicamente con los cinco CSV del paquete.
- Carga los CSV desde la misma carpeta o documenta claramente la ruta relativa.
- No corrijas archivos manualmente ni introduzcas métricas calculadas fuera del código.
- Toda exclusión o deduplicación debe justificarse y conservar el dato bruto.

Hipótesis de dimensionamiento

- Captura actual: 2 horas y 500 dispositivos.
- Escenario futuro: 30.000 dispositivos.
- Tamaño modelado: 240 bytes por evento.
- Retención: 30 días frecuentes y 5 años de histórico.
- Pico: 20 % a 1 evento/s; resto a 1 evento cada 10 s.
- Operación conservadora: 24 h/día, 365 días/año.

Alcance

- No se pide desplegar Kafka, Spark, Flink ni servicios cloud.
- La capacidad nominal no demuestra alta disponibilidad ni latencia: indica cómo las verificarías.

18. Entrega

1	Notebook de investigación	Código ejecutable, métricas, controles de calidad y evidencias.
2	Propuesta técnica	PDF de 3-4 páginas orientado a dirección.
3	Diagrama	Arquitectura con flujo, componentes y decisiones justificadas.
4	Entrega final	ZIP con los archivos anteriores; no incluyas los CSV originales.

Nombre recomendado: apellido1_nombre_M4_P3.zip

- estimación de crecimiento;
- componentes seleccionados;
- coste mensual y anual;
- arquitectura;
- justificación final.

Todos los archivos deberán entregarse dentro de:

`Apellido_Nombre_P3.zip`

19. Evaluación

La práctica se evaluará sobre 10 puntos.

Apartado	Peso
Investigación mediante Python	20 %
Detección e interpretación de problemas	15 %
Análisis de latencia y calidad	15 %
Escalabilidad y cálculos de volumen	10 %
Diseño de arquitectura	20 %
Selección de componentes y coste	10 %
Propuesta técnica, diagrama y justificación	10 %
Total	**100 %**

Se valorará especialmente:

- investigar los datos en lugar de limitarse a ejecutar funciones;
- encontrar patrones y no únicamente errores individuales;
- relacionar los resultados obtenidos con el problema de negocio;
- comprobar mediante código el requisito de latencia;
- dimensionar la solución para el volumen esperado;
- respetar el presupuesto;
- evitar sobredimensionar innecesariamente la arquitectura;
- justificar cada decisión técnica.